


@ SVM - 서포트 벡터 머신

Introduction

% 서포트 벡터 머신support vector machine은 줄여서 SVM

% 인공 신경망이 딥러닝deep learning을 통해 인공지능 분야의 중심으로 떠오르기 전에 가장 각광받던 학습 방법 중의 하나



% 파란색 원과 노란색 사각형은 서로 다른 그룹에 속한 데이터들이다. 이들을 구분하는 초평면hyperplane은 여러 개가 존재할 것

~ 여기서는 h_1 과 h_2 라는 두 개의 직선으로 표현


% 좋은 분리 평면은 새로운 데이터가 들어왔을 때에도 판정을 잘 할 수 있는 평면


% 초평면을 화살표로 표시된 법선normal 벡터 방향으로 움직였을 때 데이터에 닿지 않는 폭이 넓을수록 좋을 것

% SVM은 두 데이터 그룹을 나누는 초평면을 찾으면서 이 폭이 가장 넓은 것을 찾는 방법

~ 이 폭을 마진margin이라고 부름

~ 그림에서 볼 수 있는 것처럼 어떠한 데이터도 이 마진 내에 들어오지 않을 경우 마진을 하드 마진hard margin이라고 부름





% 마진 안에 아무런 데이터도 들어오지 않도록 하는 것이 불가능하거나 어떤 데이터는 잡음에 가까워 무시하는 것이 좋을 수도 있음

% 일부 데이터가 마진 내에 들어오도록 허용하면서 분리 평면을 찾을 수 있을 경우 소프트 마진soft margin이라고 부름

% 하드 마진이든 소프트 마진이든 마진을 최대한 넓게 만들려고 하기 때문에 마진의 양 쪽에는 서로 다른 그룹에 속하는 데이터들이 하나씩 닿아 있으며 이것을 서포트 벡터 support vector 라고 함

% 하드 마진을 사용할 경우에는 분류가 안될 수도 있고, 잡음에 민감할 수밖에 없으므로 소프트 마진을 사용하는 것이 바람직

~ 잡음에 민감하다는 것은 데이터에 과적합된다는 의미

~ 소프트 마진을 사용하는 것도 모델 정착화의 일종


% 소프트 마진을 사용할 때는 마진 내에 들어갈 수 있는 데이터의 수를 제어하며 이 값을 제어하는 변수를 슬랙slack

하드 마진 서포트 벡터 머신의 구현

% 서포트 벡터 머신의 기본적인 동작은 아래 그림과 같이 설명

% 레이블이 부여된 데이터 입력이 존재하는 공간이 회색 초평면으로 나타나 있고, 그 위에 흰색 레이블과 푸른색 레이블을 가진 데이터가 놓여 있음

% 이 공간에 존재하는 독립변수에 의해 결정되는 종속 변수 h 를 $w^t x + b$ 라고 정의하면, $h = w^t x + b$ 은 노란색으로 비스듬하게 표시된 초평면




~ 마진margin에 대한 제약 조건이 없다면, 서포트 벡터 머신은 흰색 레이블의 데이터들은 h 가

음수, 푸른색 레이블의 데이터들은 h 가 양수가 되게 하는 w 와 b 를 찾으면 됨

~ 답이 되는 평면이 하나가 아니며 이런 경우에는 가장 “좋은” 평면을 찾아야함

~ 서포트 벡터 머신에서는 마진의 넓이가 큰 값이 될수록 좋은 답

% 평면을 수직선에 가깝게 눕혀보자. 직선으로 생각하면 기울기에 해당하는 w 벡터가 0에 가까워지는 것 이려면 마진이 점점 넓어지는 것을 확인할 수 있음



$$\begin{aligned} \text{Minimization:} \quad & \arg \min_{w,b} \frac{1}{2} w^t w \\ \text{subject to} \quad & |w^t x_i + b| \geq 1 \end{aligned}$$

소프트 마진 서포트 벡터 머신의 구현

% 소프트 마진에는 슬랙slack 변수가 사용됨


% 이 슬랙 변수는 각 데이터 인스턴스마다 정의되므로 m개의 데이터 인스턴스가 있으면 각각에 대해 ξ_i 가 존재

% 슬랙 변수가 하는 일은 각각의 데이터가 [-1, 1] 사이의 범위를 갖는 마진 안으로 들어갈 수 있는 정도를 의미

~ 하드 마진은 $\xi_i = 0$

% 슬랙 변수에 의해 각각의 데이터 인스턴스에 대해 제약 조건이 다음과 같이 변경

$$\text{subject to } |w^t x_i + b| \geq 1 - \xi_i$$



% 그림으로 나타내면 아래와 같다. 각각의 데이터 인스턴스는 마진 밖이나 안에 존재할 수 있는데, 마진 내에 많이 파고 들어올수록 슬랙 변수의 값이 커지는 것

~ 좋은 분류를 위해서는 슬랙 변수를 최소로 만드는 최적화 문제를 풀

$$\begin{aligned} \text{Minimization:} \quad & \arg \min_{w,b} \frac{1}{2} w^t w + C \sum_i \xi_i \\ \text{subject to} \quad & |w^t x_i + b| \geq 1 - \xi_i \end{aligned}$$

파이프라인을 이용한 데이터 정제

- % SVM은 데이터의 크기에 민감한 특성을 갖고 있음
- % 데이터 정제를 위해 정규화normalization 혹은 표준화standardization을 수행함
- % 사이킷런 패키지는 이를 위해 파이프라인pipeline이라는 편리한 방법을 제공

다항 특징 변환을 통한 비선형 서포트 벡터 머신의 구현

- % 다항 특징 변환을 하면 새로운 특징 x^2 이 추가되어 데이터는 화살표 오른쪽처럼 2차원 평면에 존재하고, 분리 평면도 존재
- ~ 원래의 입력 공간에서 보면 비선형 곡면을 통한 분류와 같은 효과

