Machine Learning — Midterm Report

보고서 제출은 하나의 **PDF** 파일로 제출**:** 홍길동**.pdf**

Problem 1 — FA-roid: Does Performance Decline After an FA Contract? (15점)

문제 배경

프로야구에서는 FA(Free Agent) 계약을 앞둔 선수가 좋은 성적을 기록하다가, FA 계약을 체결한 이후에는 성적이 하락하는 현상을 이른바 'FA-roid'라고 부르기도 한다.

이러한 현상이 실제로 존재하는지, 또는 일부 선수들의 사례에서 비롯된 인식에 불과한지는 데이터 분석을 통해 검토할 수 있는 문제이다.

제공 데이터

`MLB_2000_2025_PlayerSeasons_Edu.csv`

본 데이터는 2000년부터 2025년까지 MLB에서 활동한 선수들의 시즌별 기록을 기반으로 구성되었다.

- 투수와 타자를 모두 포함하며, FA 선수와 비FA 선수를 모두 포함한다.
- 선수들의 시즌별 타격 및 투구 성적은 실제 MLB 기록을 기반으로 한다.
- FA 계약 여부와 계약 시점은 교육 목적으로 생성한 모의 데이터이며, 실제 선수들의 FA 계약 이력과는 다르다.
- 일부 선수의 기록에는 결측치가 포함되어 있다.

따라서 본 데이터의 분석 결과는 교육용 모의 FA 계약에 대한 결과이며, 실제 MLB의 FA 계약 효과를 입증하는 자료로 해석해서는 안 된다.

수행 과제

제공된 데이터를 분석하여 다음 질문에 대한 자신의 주장을 제시하시오.

"FA 계약을 체결한 선수들은 계약 전과 비교하여 계약 이후에 성적이 하락하는 경향을 보이는가?"

자신의 주장을 뒷받침하기 위해 적절한 데이터를 선택하고, 필요한 분석과 실험을 수행하시오.

보고서에는 다음 내용이 포함되어야 한다.

1. 연구 문제에 대한 자신의 주장 또는 가설
2. 분석 대상 및 데이터 선정 근거
3. 분석 방법과 실험 결과
4. 분석 결과에 근거한 주장과 결론
5. 연구의 한계 및 결과 해석 시 고려해야 할 사항

분석 대상, 성적 평가 지표, 비교 기간 및 분석 방법은 학생이 스스로 결정해야 하며, 그 선택의 타당성을 설명해야 한다.

평가 기준 **(15**점**)**

본 보고서는 다음 5개 항목에 대해 각각 3점씩, 총 15점 만점으로 평가한다.

각 평가 항목은 제출된 보고서를 상호 비교하는 상대평가 방식으로 평가하며, 평가 수준은 상·중·하로 구분한다.

평가 항목	배점
연구 문제와 주장의 명확성	3점
데이터 선정 및 분석 대상 구성의 적절성	3점
분석 방법과 실험 결과의 타당성	3점
결과 해석 및 논리적 주장	3점
설명 및 표현력 (Table·Graph 등 시각화 포함)	3점
합계	15점

평가 수준별 점수는 다음과 같다.

- 상(3점): 다른 보고서에 비해 해당 항목의 완성도가 우수한 경우
- 중(2점): 해당 항목의 완성도가 보통 수준인 경우
- 하(1점): 해당 항목의 완성도가 상대적으로 부족한 경우
- 0점: 해당 항목을 수행하지 않았거나 평가할 내용이 없는 경우

각 항목은 제출된 보고서들의 상대적인 완성도를 기준으로 평가한다. 따라서 단순히 분석을 수행하거나 결과를 제시했다는 사실만으로 높은 점수가 보장되지는 않는다.

유의사항

- 특정한 결론을 요구하지 않는다. FA-roid가 존재한다는 주장과 존재하지 않는다는 주장 모두 가능하다.
- 주장의 설득력은 분석 결과와 논리적 근거를 중심으로 평가한다.
- 단순한 통계 수치나 Graph의 나열만으로는 충분하지 않다.
- 제공된 데이터의 특성과 한계를 고려해야 한다.
- Python 코드 작성 및 오류 수정 등 기술적인 작업에는 AI 도구를 사용할 수 있으나, 가설 설정, 결과 해석, 주장 및 결론 작성에는 사용할 수 없다.
- 다른 학생의 보고서를 복사하거나 출처 없이 타인의 자료를 사용하는 표절 행위는 금지한다. 제출된 보고서는 AI 기반 표절 검사 도구를 이용하여 검토한다.
- 사용한 분석 방법과 결과는 학생 본인이 이해하고 설명할 수 있어야 한다.
- LMS에 지정된 제출 마감시간을 엄수해야 하며, 마감 이후 제출은 인정하지 않는다.

Problem 2 — Customer Churn Prediction (15점)

문제 배경

기업에서는 고객의 서비스 이용 기록을 분석하여 향후 서비스를 중단할 가능성이 있는 고객을 예측하고자 한다.

그러나 동일한 Data를 사용하더라도 Feature의 선택, Training Data의 구성, Machine Learning Model의 종류 등에 따라 Prediction Performance는 달라질 수 있다.

따라서 적절한 Feature를 선정하고, 서로 다른 Machine Learning Model의 예측 성능을 비교하여 그 결과를 합리적으로 해석하는 것이 중요하다.

제공 데이터

`customer_churn_midterm.csv`

본 데이터는 고객의 서비스 이용 기록을 바탕으로 구성한 교육용 모의 데이터이다.

- 전체 1,000명의 고객 Data를 제공한다.
- 20개의 Feature와 고객 이탈 여부를 나타내는 `Churn`이 포함되어 있다.
- `Churn=1`은 서비스 이탈, `Churn=0`은 서비스 유지를 의미한다.
- 일부 Feature는 예측에 불필요하거나 다른 Feature와 높은 상관관계를 가질 수 있다.
- `DataSplit` 열은 고정된 Training/Test 구분을 나타낸다.

수행 과제

제공된 Data를 이용하여 고객의 서비스 이탈 여부를 예측하는 Machine Learning Model을 개발하시오.

20개 Feature 중 예측에 필요하다고 판단되는 Feature를 스스로 선정하고, 다음 세 가지 Machine Learning Model을 모두 적용하여 Prediction Performance를 비교하시오.

1. Logistic Regression
2. Decision Tree
3. Support Vector Machine (SVM, RBF Kernel)

세 Model의 실험 결과를 분석하여 다음 질문에 대한 자신의 주장을 제시하시오.

"세 가지 Machine Learning Model 중 고객 이탈을 예측하는 데 가장 적절한 Model은 무엇이며, 그 이유는 무엇인가?"

실험 조건

- 전체 Data 중 200명은 Test Set으로 고정되어 있으며, `DataSplit` 열에 `TEST`로 표시되어 있다.
- 나머지 800명은 Training에 사용할 수 있는 Data이며, `TRAIN`으로 표시되어 있다.
- Feature의 수와 구성은 학생이 스스로 결정하되, 선정하거나 제외한 이유를 설명해야 한다.
- 세 Model의 공정한 비교를 위해 동일한 Feature 구성과 Test Set을 사용한다.
- Feature Selection, Data Preprocessing 및 Training 방법은 학생이 스스로 결정한다.
- Hyperparameter Tuning은 필수사항이 아니며, 필요하다고 판단하는 경우 수행할 수 있다.
- Test Set은 최종 Prediction Performance 평가에만 사용한다.

보고서 작성 내용

보고서에는 다음 사항이 포함되어야 한다.

1. 연구 문제에 대한 자신의 주장
2. Data의 특성과 Feature 선정 및 제외 근거
3. Training 전략 및 Data Preprocessing 방법

4. 세 Model의 Prediction Performance 비교
5. 실험 결과에 근거한 최종 Model 선정과 그 이유
6. 분석 결과의 한계 및 개선 가능성

특히 Feature의 선정과 제외는 중요한 평가 요소이다. 단순히 Feature의 개수를 줄이거나 모든 Feature를 사용하는 것보다는, Data 분석에 근거하여 그 선택의 타당성을 설명해야 한다.

또한 가장 높은 Accuracy를 얻은 Model을 선택하는 것만으로는 충분하지 않다. 실험 결과와 Model의 특성을 근거로 자신의 주장을 논리적으로 전개해야 한다.

평가 기준 **(15**점**)**

본 보고서는 다음 5개 항목에 대해 각각 3점씩, 총 15점 만점으로 평가한다.

각 평가 항목은 제출된 보고서를 상호 비교하는 상대평가 방식으로 평가하며, 평가 수준은 상·중·하로 구분한다.

평가 항목	배점
연구 문제와 주장의 명확성	3점
Feature 선정 및 제외 근거의 적절성	3점
Training 전략 및 비교 실험의 타당성	3점
결과 해석 및 논리적 주장	3점
설명 및 표현력 (Table·Graph 등 시각화 포함)	3점
합계	15점

평가 수준별 점수는 다음과 같다.

- 상(3점): 다른 보고서에 비해 해당 항목의 완성도가 우수한 경우
- 중(2점): 해당 항목의 완성도가 보통 수준인 경우

- 하(1점): 해당 항목의 완성도가 상대적으로 부족한 경우
- 0점: 해당 항목을 수행하지 않았거나 평가할 내용이 없는 경우

각 항목은 제출된 보고서들의 상대적인 완성도를 기준으로 평가한다. 따라서 단순히 세 Model을 실행하거나 높은 Accuracy를 얻었다는 사실만으로 높은 점수가 보장되지는 않는다.

유의사항

- 모든 학생은 동일한 제공 Data와 지정된 세 가지 Model을 사용해야 한다.
- Feature의 개수에는 제한이 없으며, 선정 및 제외 근거를 설명해야 한다.
- 800개의 `TRAIN` Data를 모두 Training에 사용할 필요는 없다. 일부를 Validation에 활용하거나 필요한 Data만 선택하여 사용할 수 있으며, 그 이유를 설명해야 한다.
- 모든 Model의 Hyperparameter를 최적화할 필요는 없다. 기본 설정을 사용해도 무방하다.
- `Churn`은 예측할 Target이고, `DataSplit`은 Data 구분을 위한 열이므로 Prediction Feature에 포함해서는 안 된다.
- Test Set 200개는 변경할 수 없으며, Feature Selection이나 Hyperparameter를 결정하는 데 사용해서는 안 된다.
- 특정 Model이 반드시 우수해야 한다는 정답은 없다.
- 높은 Accuracy 자체보다는 Feature 선정의 타당성, 실험 결과에 대한 이해와 논리적인 해석을 중요하게 평가한다.
- 단순한 실행 결과나 Graph의 나열만으로는 충분하지 않다.
- Python 코드 작성 및 오류 수정 등 기술적인 작업에는 AI 도구를 사용할 수 있으나, 가설 설정, 결과 해석, 주장 및 결론 작성에는 사용할 수 없다.
- 다른 학생의 보고서를 복사하거나 출처 없이 타인의 자료를 사용하는 표절 행위는 금지한다. 제출된 보고서는 AI 기반 표절 검사 도구를 이용하여 검토한다.
- LMS에 지정된 제출 마감시간을 엄수해야 하며, 마감 이후 제출은 인정하지 않는다.